진행 상황 통합 — 2026-09-18 자문 이후

> **4쪽 요약본이 따로 있습니다 →** `summary.pdf` **.** 멘토·심사 제출에는 그쪽을 쓰세요. 이 문서는 근거와 과정이 전부 들어간 원본입니다.
> **이 문서 하나면 됩니다.** 멘토 자문 이후 무엇을 했고 지금 어디까지 왔는지를 모아 두었습니다. 멘토 보고도, 팀 내부 공유도 이것으로 합니다.
> 세부 기록이 필요할 때만 원본을 보세요 — 2·3장 표에 어느 문서인지 적어 두었습니다.
> 2026-10-21 기준 · 담당 B 임준서 · 담당 C/D 박현준 · 담당 D 이동현

---

1. 한눈에 — 자문 항목별 현황

#	멘토 자문 (9/18)	현황
1	4초 고정 분할 → **인접 세그먼트 의미 단위 병합**	**완료(5-5장).** 구현·측정했고 **채택하지 않음.** 검색은 +9%p 좋아지지만 top-5 가 짚는 정답 수가 줄어 −0.071. 구제책(조각으로 이동)과 **천장(오라클)까지 재서** 이득 없음을 확인
2	**신호별 역할 규명** (핵심 기여)	**제거법 15조건 전수 완료(5-2장).** SigLIP 단독은 무작위와 구별 안 됨. 재료·분량은 자막 위주가 유의하게 낫고 시각적 상태는 정반대 — 전체 평균에서 상쇄됨
3	근거 부족 시 **"관련 장면 없음"**	**완료(5-6장).** 0/12 → (가)분야 다름 10/10 · (나)장면만 없음 7/12, 잘못된 거절 6/48. 운영점 0.52 는 데이터로 선택
4	영상 1건당 **처리 시간·비용 실측**	**완료(5-3장).** 서버 처리 평균 112초(영상 길이의 2.4배), 그중 81%가 프레임 단계. 하루 20개가 한계
5	**저작권 범위** 발표 자료에 명시	**완료(5-4장).** 발표 자료에 넣을 문단 작성
—	**평가 설계** (등급형 nDCG · 유형별 · 기준선 · 편향 방지)	**완료.** 질문 64개, 라벨 113줄, 측정 스크립트
—	추진 일정표 · 역할 분담표	미착수

핵심: 멘토가 지목한 보완 5가지가 **전부 처리됐습니다.** 전부 "좋아졌다" 는 아닙니다 — 자문 1(병합)은 **해보고 채택하지 않았고, 왜 안 되는지가 결과**입니다. 자문 2는 신호별 역할이 질문 유형에 따라 **정반대**라는 것을 찾았고, 자문 3은 0/12 에서 (가)10/10 · (나)7/12 로 바꿨습니다. **측정 → 개선 → 재측정 루프를 다섯 번 돌린 것 자체가 기여입니다.**

1-2. 2차 자문 (2026-10-12) 대응 현황

> 평가자 우슬기 (㈜케이티 차장) · 중간평가 **87/100**

멘토 요구	상태
외부 질문·시간 구간 정답·nDCG@5 평가 체계 구축, 신호 조합별 기여도 확인	**칭찬** — 할 일 없음
답 없는 질문 대응("관련 장면 없음" 판정)	**완료** (5-6장)
처리 시간·비용 측정	**완료** (5-3장, `tools/cost_report.py`)
장면 설명 완료 후 공식 기준선 확정 + 비용 대비 효과 재검토	**완료** (5장 · 5-2장)
순서·타이밍 질문 개선 (조리 단계 단위 병합)	**시도·측정했고 채택하지 않음** (5-5장)
사용자 평가로 서비스 가능성 제시	**완료(5-7장).** 10명 · 60과제. 장면 찾기 **27.3초 → 9.3초(66% 단축)**, 10명 전원 개선, 부호검정 p=0.002

2차 자문 요구가 전부 처리됐습니다. 마지막 항목이던 사용자 평가를 2026-10-26 에 진행했고 결과는 5-7장에 있습니다.

> 순서·타이밍 개선은 멘토가 "조리 단계 단위 병합" 을 구체적으로 지목했는데, 저희가 병합을 구현해 재보니 **순서·타이밍이 0.709 → 0.619~0.715 로 거의 안 움직이고 전체는 떨어졌습니다.** 정답 위치를 보고 조각을 고르는 치트(오라클)로 천장을 재도 기준선을 못 넘었습니다. 다만 저희가 시험한 규칙은 "같은 발화가 카드에 복사된 것을 합치기" 였고 "조리 단계 단위" 와 정확히 같지는 않습니다 — 보고할 때 그대로 적으세요.

---

2. 지금 시스템이 어떻게 구성돼 있나

유튜브 쇼츠를 저장하면 크롬 확장이 영상을 재생하며 **0.5초마다 화면을 캡처**하고 **오디오를 녹음**해 서버로 보냅니다. 서버가 **4초 단위 장면 카드**로 쪼갭니다.

단계	쓰는 것	비고
음성 받아적기	`faster-whisper` (로컬)	WhisperX 는 Python 3.14 미지원
화면 자막	`EasyOCR` (로컬)	
장면 설명	**Gemini** (`gemini-3.5-flash`)	유일한 외부 호출. 영상당 1회
글 좌표	`BGE-M3` 1024차원 (로컬)	
그림 좌표	`SigLIP2-naflex` 768차원 (로컬)	질의를 영어로 번역해 사용

9/18 이후 가장 큰 변화는 색인 단계가 전부 로컬 모델로 옮겨간 것입니다. 외부로 나가는 호출이 영상당 3회에서 **1회**(장면 설명)로 줄었습니다.

검색은 **세 신호를 가중합**합니다 — 글 좌표 · 정확한 단어(IDF 가중) · 그림 좌표. 가중치 9개는 아직 사람이 감으로 정한 상수이고, **이것을 데이터로 정하는 것이 자문 2번**입니다.

현재 영상 **18개**, 장면 카드 **203개**.

자문을 반영하며 생긴 **조절 스위치**는 전부 `.env` 한 줄로 켜고 끕니다:

설정	지금 값	뜻
`NO_ANSWER_THRESHOLD`	**0.52**	근거가 약하면 경고 (자문 3 · 5-6장). 0 이면 끔
`MERGE_SIMILARITY`	**0**	의미 단위 병합. **꺼짐** — 재보니 손해였습니다 (자문 1 · 5-5장)
`SEEK_LOCALIZE`	1	병합 카드 안에서 이동 지점 고르기. 병합이 꺼져 있어 무해
`MAX_GEMINI_CALLS_PER_VIDEO`	1	영상당 Gemini 호출 상한 (자문 4 · 5-3장)

---

3. 무엇을 고쳤나 — 버그 16개

세 사람이 각자 찾은 것을 모았습니다. **대부분이 에러 없이 조용히 틀린 값을 내고 있었습니다.** 서버는 정상으로 보이고 영상도 "완료"로 끝났습니다.

박현준 (10/05) — `docs/fixes-20261005.md`

증상	원인
음성이 모든 영상에서 빈 값	PyAV 15+ 에서 `av.open(metadata_errors=)` 인자가 사라져 faster-whisper 가 오디오를 열 때마다 죽었고, 예외를 삼켜 빈 결과가 됐습니다
말 없는 영상에서 **없는 말을 지어냄**	위를 고치자 드러났습니다. VAD 필터 코드가 **이미 있었는데** 그 줄에 도달조차 못 하고 있었습니다. BGM만 있는 영상에서 환각 15개 → 0개
자막에 쓰레기·채널 로고·중복	신뢰도를 버리고 있었습니다(`detail=0`). 채널 워터마크가 매번 다르게 읽혀 단순 중복 제거로 안 걸렸습니다
정답 장면의 양 옆 카드가 항상 삭제	4초 카드는 맞닿아 있어 겹침이 0인데, 앞뒤 2초 여유 때문에 전부 중복 판정됐습니다. 라벨링 허용 오차가 이전 5초인 것을 생각하면 평가에 치명적이었습니다
단어 점수가 상시로 깎임	코퍼스에 없는 단어가 최대 IDF 를 받아 분모만 키웠습니다. `"장면"` 처럼 질의에 늘 있고 어느 카드에도 없는 단어가 모든 검색의 점수를 깎았습니다
저장한 영상 제목이 전부 같음	유튜브 쇼츠 DOM 변경. `video_id` 는 멀쩡해서 알아채기 어려웠습니다
재색인이 **SigLIP 벡터를 삭제**	Qdrant 는 같은 id 로 upsert 하면 포인트를 통째로 교체합니다. 글 좌표만 넣으면 그림 좌표가 사라집니다

박현준 (10/08) — 재현성

질의 번역 캐시를 디스크에 저장. SigLIP 은 한국어가 약해 그림 좌표용 질의만 영어로 번역하는데, 캐시가 메모리에만 있어 서버를 껐다 켜면 다시 번역됐습니다. 같은 질의에서 1위가 바뀌는 것이 관측됐고, **이 상태로는 점수가 좋아져도 개선 때문인지 번역이 달라져서인지 구분할 수 없어 평가 자체가 불가능**했습니다.

임준서 (10/08) — 실패를 드러나게

분석 단계가 실패해도 빈 결과로 넘어가 영상이 정상(ready)으로 저장되던 문제를 고쳤습니다. 평가셋에 이런 영상이 섞이면 신호별 기여도를 잴 때 원인을 구분할 수 없습니다.

- 단계별 상태 기록 `analysis_health` — `ok` / `ok_empty` / `skipped` / `error` 구분
- Gemini 오류 등급 구분 — **일일 할당량 소진은 재시도 없이 즉시 멈춤**(몇 초 뒤 재시도로는 풀리지 않아 저장 시간만 늘고 원인도 묻힘). 분당 한도·서버 장애는 `retryDelay` 만큼 쉬고 재시도
- 음성 응답이 비면 "말 없는 영상" 대신 `EMPTY_RESPONSE` 오류로
- OCR 실패 프레임 수를 세고, 전부 실패하면 `OcrFailed`
- 로컬 모델 공용 잠금(동시 저장 시 같은 모델 두 벌 방지)
- 보관함 카드에 "⚠ 일부 분석 실패" 경고
- 자동 테스트 66개

> **이 작업이 아래 10/10 버그 3개를 찾아낸 도구가 됐습니다.** 단계별 기록이 없었으면 자막이 통째로 비어 있다는 사실을 끝까지 몰랐을 것입니다.

이동현 (10/09~10) — `docs/fixes-20261010.md`

증상	원인
분석이 전부 실패	**`.env` 의 빈 값 뒤 인라인 주석을 값으로 읽음.** `SIGLIP_ADAPTER= # 설명...` 에서 주석 전체가 값이 되어 없는 폴더를 찾다가 죽었습니다. 값이 **있는** 줄은 정상이라 눈에 안 띕니다
좌표 저장 실패	글 좌표를 768→1024차원으로 바꿨는데 **창고가 768 그대로**. 삭제 명령이 메타데이터만 바꾸고 저장 파일을 남겼습니다
자막이 통째로 빔	EasyOCR 에 경로를 넘기면 내부에서 OpenCV 를 쓰는데, **OpenCV 는 윈도우에서 한글 경로를 못 엽니다.** 프로젝트 폴더 이름에 한글이 있어 전 프레임 실패. OCR 이 비면 Gemini 가 읽은 글자가 대신 채워져 겉보기로는 정상이었습니다
저장 버튼이 엉뚱한 영상을 보냄	Side Panel 이 탭 전환만 감지해, 쇼츠를 스크롤해도 이전 영상 정보를 들고 있었습니다
임베딩 429 에 저장 전체가 실패	캡션·음성에는 있던 재시도가 임베딩에만 빠져 있었습니다
nDCG 가 1 을 초과	평가 스크립트 버그. 허용 오차가 넓어 맞닿은 카드 여러 장이 같은 정답에 걸렸고 매번 득점했습니다

> **`.env` 주석 문제와 EasyOCR 한글 경로 문제는 환경만 맞으면 누구나 겪습니다.** `.env.example` 은 고쳤지만 **각자 이미 만든 `.env` 는 따라오지 않습니다.**

수정 효과 (측정된 것)

	전	후
OCR 단계 성공	18개 중 **0개**	18개 중 **18개**
자막이 들어간 장면	(전부 Gemini 폴백)	**190/203 (94%)**
말이 들어간 장면	0/24 (현준 측정)	**163/203 (80%)**

---

4. SigLIP2 — 파인튜닝을 해보고 버렸다 (박현준)

원본: `SigLIP2_실험기록_20260914.md`

이 실험의 결론은 한 번 뒤집혔습니다. 초판(9/14)은 RecipeGen(영어 웹사진) **단일 테스트셋**에서 측정해 선형 정렬 채택으로 결론했는데, 9/17 에 실제 도메인인 한국어 쇼츠 1,468쌍으로 2차 평가를 하자 **부호가 뒤집혔습니다.**

조건	RecipeGen	실제 쇼츠
무작위	0.179	0.115
사전학습 그대로	0.685	0.658
+ 텍스트 LoRA	**0.790**	0.664 (구분 안 됨)
+ 선형 정렬	0.784	**0.595** (유의하게 나쁨)

초판 수치를 지우지 않고 남겨 두었습니다. 틀린 숫자가 아니라 **좁은 테스트셋에서는 맞는 숫자**였고, 그걸로 모델을 고르면 어떻게 틀리는지가 이 실험의 결론이기 때문입니다.

제품에 들어간 것은 질의 전처리 세 줄뿐입니다 — 영어 번역(+0.138), 소문자화, `a photo of {}` 템플릿. 학습한 가중치는 하나도 들어가지 않았습니다.

> 발표용 한 줄: **"학습 없이 질의를 영어로 번역하는 것만으로 맞는 순간을 찾는 비율이 52% 에서 66% 로. 무작위는 12%. 두 종류로 파인튜닝해봤지만 실제 데이터에서는 이득이 없었다."** 파인튜닝을 안 한 것이 아니라 **해보고 버렸다**는 점이 결과입니다.

---

5. 평가셋과 첫 측정

평가셋 (자문「평가 방법」)

항목	내용
질문	**64개** — 팀원 4명이 각자 **팀 외부 지인**에게 받았습니다
정답 라벨	**113줄** — 전부 팀원이 직접 작성. 2점 49 / 1점 51 / "정답 없음" 13
등급	정확 2 / 관련 1 / 무관 0 (적지 않으면 0)
정답 단위	**시간 구간(초)** — 세그먼트 번호가 아닙니다. 자문 1번(의미 단위 병합)을 적용해도 평가셋을 다시 만들 필요가 없습니다
허용 오차	**비대칭** — 정답 시작의 이전 5초 ~ 이후 2초
편향 방지	질문을 팀 외부에 의뢰 (자문 5번의 "또는" 조건)

작업 지침은 `docs/eval-guide.md`, 데이터는 `eval/labels_merged.csv` 와 `eval/labeling_sheet.xlsx`.

공식 기준선 (2026-10-21, 질문 48개 + 정답 없음 12개) · `eval/result_20261021.json`

장면 설명을 다 채운 뒤에 잰 값입니다. 2차 자문이 "장면 설명 생성 완료 후 공식 기준선을 확정" 하라고 전제를 걸었고, 그 조건을 채웠습니다(채움률 81% — 아래 설명).

	nDCG@5	Recall@5	mAP	1위적중
기준선 — 음성 단일 신호	0.719	0.802	0.607	0.625
현행 시스템	**0.745**	0.802	0.621	0.688
개선폭	**+0.027**	—	+0.014	+0.063

유형별: 재료·분량 **0.689** · 순서·타이밍 **0.688** · 시각적 상태 **0.899**

⚠ 설명을 채웠더니 전체 점수가 내려갔습니다

	설명 55% (10/13)	설명 81% (10/21)
현행 전체	0.756	**0.745**
시각적 상태	0.886	**0.899** ↑
재료·분량	0.707	**0.689** ↓
순서·타이밍	0.709	**0.688** ↓

제거법이 예측한 그대로입니다(5-2장) — 장면 설명은 **시각적 상태에는 도움이 되고 재료·분량에는 노이즈**입니다. 설명을 더 넣으니 그 둘이 더 벌어졌고, 합쳐서는 손해가 됐습니다. **이것이 2차 자문 ②("비용 대비 효과 재검토")에 대한 답의 출발점입니다.**

채움률 81% 가 "완료" 인 이유 — 100% 는 설계상 불가능합니다

한 영상이 받을 수 있는 설명 지점은 `GRID_FRAMES(12) × MAX_GEMINI_CALLS_PER_VIDEO(1) = 12개` 로 고정입니다. 장면이 12개를 넘는 영상 9개는 **구조적으로** 다 채울 수 없습니다.

영상	장면	설명	
`OgR00HBMKFs`	23	12	상한에 막힘
`Zlo2JQzihwc`	20	12	상한에 막힘
`11C8XqWobjQ`	10	10	완전

이론상 최대 167/203 = 82%, 실제 165/203 = 81%. 사실상 꽉 채웠습니다. 더 올리려면 `MAX_GEMINI_CALLS_PER_VIDEO` 를 올려야 하고, 하루 처리량이 그만큼 줍니다(1회 → 영상 20개/일, 2회 → 10개/일). **이 교환 자체가 자문 ②의 자료입니다.**

채우는 도구: `python -m tools.backfill_captions --yes` (다시 저장할 필요 없음)

유형별로 신호 기여가 갈린다 — 자문 2번이 요구한 형태

유형	현행	음성만	차이	n
시각적 상태	0.886	0.839	**+0.047**	13
재료·분량	0.707	0.663	+0.044	19
순서·타이밍	0.709	0.715	**−0.006**	16

순서·타이밍 질문은 음성만 쓰는 쪽이 근소하게 나았습니다. 조리 순서는 말로 설명되는 경우가 많아, 자막·그림이 도움이 되기보다 노이즈로 작용한 것으로 보입니다.

다만 이 "음성만" 기준선은 약합니다. 현행 검색이 뱉은 후보를 받아 **순위만** 음성으로 다시 매긴 것이라, 후보 자체는 세 신호가 섞인 색인에서 나옵니다. 그래서 아래 제거법을 따로 돌렸습니다.

5-2. 제거법 — 네 신호 중 무엇이 맞히고 있나 (자문 2번 본답)

`tools/ablation.py` · 결과 원자료 `eval/ablation.json`

왜 이게 필요했나. 색인할 때 `segmenter.search_text()` 가 제목·설명·음성·자막을 **문자열 하나로 붙여** 좌표 1개를 만듭니다. 검색이 맞혀도 어느 신호 덕인지 점수만 봐서는 알 수 없습니다. 그래서 **빼보고 얼마나 떨어지는지** 재는 수밖에 없고, 신호가 4개 (음성·자막·설명·그림)라 조합이 $2^4-1 = 15$개뿐이라 전수로 돌렸습니다.

글 세 가지는 장면 카드에서 그 필드를 **빈 문자열로 만들어 색인**해 뺍니다. 글 좌표와 단어 점수가 함께 그 필드를 못 보게 됩니다 — 단어 점수는 Qdrant payload 를 읽으므로 payload 도 같이 비워야 하고, 벡터만 비우면 단어 채널로 정보가 새어 과대평가됩니다. 그림(SigLIP)은 글이 아니라 별도 좌표라, 그 조건에서는 **창고를 그림 벡터 없이 만듭니다. 제품 코드는 한 줄도 바꾸지 않았고**, 조건마다 창고를 따로 만들어 제품과 같은 `search()` 를 `condition=` 만 바꿔 불렀습니다(설계 원칙 6). Gemini 호출 0회.

표본: 영상 **18개** / 장면 **203개** / 질문 **48개**(재료·분량 19 · 순서·타이밍 16 · 시각적 상태 13). 10/21 에 장면 설명을 다 채운 뒤 다시 돌렸으므로 **빠는 영상이 없습니다** — 공식 기준선(5장)과 같은 표본이라 두 표를 바로 비교할 수 있습니다.

#	조건	nDCG@5	기준대비	답하는 질문
1	음성+자막+설명+그림	0.745	—	기준 (= 현행 제품)
2	음성+자막+설명	0.734	−0.011	**SigLIP 이 필요한가**
3	**음성+자막+그림**	**0.772**	**+0.026**	**Gemini 없이 로컬만으로 되나**
4	음성+설명+그림	0.765	+0.020	EasyOCR 이 필요한가
5	자막+설명+그림	0.697	**−0.049**	**Whisper 가 필요한가**
6	음성+자막	0.744	−0.001	
7	음성+설명	0.721	−0.024	
8	음성+그림	0.719	−0.026	
9	자막+설명	0.673	−0.072	
10	자막+그림	0.700	−0.045	
11	설명+그림	0.655	−0.090	**Gemini 만으로 충분한가**
12	음성	0.717	−0.028	
13	자막	0.664	−0.082	
14	설명	0.596	−0.149	
15	그림	**0.470**	**−0.275**	**그림만으로 되나**

> 10/13 에 잰 표(기준 0.782)는 **설명이 빈 영상 5개를 빼고 13개로 돌린 것**이라 숫자가 다릅니다. 위 표가 **확정값**입니다.

2차 자문 ②에 대한 답 — 장면 설명(Gemini)은 지금 손해입니다

> 멘토: 장면 설명을 제외한 조건(0.806)이 기준선보다 높으므로, 장면 설명 생성 완료 후 공식 기준선을 확정하고 **비용 대비 효과를 재검토**할 것.

설명을 다 채운 뒤에도 빼는 쪽이 높습니다 — 0.772 vs 0.745.

비교	평균차	95% 구간	부호검정	판정
설명 빼기 (3−1)	**+0.026**	[−0.007, +0.061]	**p=0.029**	방향은 분명(↑19 / ↓7), 크기는 미확정
자막 빼기 (4−1)	+0.020	[−0.019, +0.064]	p=0.523	구분 안 됨
음성 빼기 (5−1)	**−0.049**	[−0.132, +0.027]	p=0.585	구분 안 됨이나 **가장 큰 손해**
그림 빼기 (2−1)	−0.011	[−0.043, +0.020]	p=1.000	구분 안 됨

유형별로 보면 왜 그런지가 분명합니다:

유형	설명 뺐을 때 변화	95% 구간	n	판정
재료·분량	**+0.084**	[+0.037, +0.139]	19	**유의**
순서·타이밍	+0.017	[−0.020, +0.064]	16	구분 안 됨
시각적 상태	−0.046	[−0.117, +0.013]	13	구분 안 됨

재료·분량 질문에서 장면 설명이 해롭다는 것만 통계적으로 확실합니다. 분량은 자막에 글자로 박혀 있는데 설명이 그걸 흐립니다. 시각적 상태에서 손해를 보는 것은 구간이 0을 지나 확정되지 않았습니다.

정직하게 말할 수 있는 선:

> 장면 설명을 빼면 48문항 중 19개가 좋아지고 7개가 나빠져 **방향은 분명하지만** (부호검정 p=0.029), 평균 개선폭 +0.026의 신뢰구간은 0 을 지나 **크기는 확정적이지 않습니다.** 다만 **재료·분량 유형에서는 설명이 해롭다는 것이 확실합니다** (+0.084, 구간이 0 을 벗어남).

비용 쪽은 명확합니다 — 장면 설명은 **유일한 외부 호출**이고 하루 20개 영상이라는 처리량 상한을 혼자 만듭니다(5-3장). 성능 이득이 없거나 음수인데 그 제약을 감수할 이유가 없습니다. **다만 시각적 상태 질문이 이 제품의 핵심 주장이라, 끄기 전에 그 유형의 질문을 늘려 다시 재는 것이 안전합니다.**

기준점 — 무작위로 5개를 뽑으면 0.480

같은 영상 안에서 장면 카드 5개를 무작위로 고르면 nDCG@5 **0.480** 입니다 (2,000회 시행, 95% 범위 [0.388, 0.573]). 영상 안에 카드가 4~20장뿐이라 아무렇게나 찍어도 꽤 맞습니다. **이 선을 넘지 못하면 그 신호는 작동하지 않는 것입니다.**

가장 중요한 결과 — SigLIP 단독은 무작위와 구별되지 않습니다

단독 신호	nDCG@5	무작위가 이 값을 넘은 비율
음성만	0.739	0.0%
자막만	0.735	0.0%
설명만	0.654	0.0%
그림(SigLIP)만	**0.520**	**20.1%**

SigLIP 혼자서는 영상 안에서 맞는 순간을 찾지 못합니다. 0.520 은 무작위 0.480 의 95% 범위 안에 들어갑니다.

이것은 박현준 님의 SigLIP2 실험(4장)과 **모순되지 않습니다.** 그 실험은 쇼츠 1,468쌍에서 **캡션↔프레임을 맞추는** 과제였고 (0.658), 여기는 **한 영상 안에서 4초 카드를 고르는** 과제입니다. 같은 영상의 카드끼리는 그림이 서로 비슷해 SigLIP 이 변별하지 못합니다. → **"SigLIP 은 어느 영상인지는 구분하지만, 그 영상 안 어느 순간인지는 구분하지 못한다."**

그래도 보조 신호로는 일관되게 플러스입니다

짝을 지어 그림을 뺄 때마다 **4번 모두 떨어졌습니다.**

비교	차이	95% 구간	판정
전부에서 그림 빼기	−0.014	[−0.044, +0.016]	구분 안 됨
음성+자막에서 그림 빼기	−0.030	[−0.083, +0.021]	구분 안 됨
음성+설명에서 그림 빼기	−0.035	[−0.085, +0.014]	구분 안 됨
자막+설명에서 그림 빼기	−0.031	[−0.067, −0.001]	경계 (구간은 0 을 벗어나지만 부호검정 p=0.12)

개별로는 어느 것도 유의하지 않지만 **부호가 4/4 로 같습니다.** 단독으로는 무작위 수준인 신호가 다른 신호와 함께일 때는 조금씩 보탭니다 — 순위를 뒤집지는 못해도 비슷한 후보들 사이에서 미세하게 재배열하는 역할로 보입니다. 확정하려면 표본이 더 필요합니다.

전체 평균으로는 거의 모든 쌍이 구분되지 않습니다

문항별 점수를 짝지어 부트스트랩 95% 구간을 냈습니다. **"그림만 vs 전부"(−0.262) 를 빼면 어느 비교도 구간이 0 을 지납니다.** 표의 차이는 n=31 에서 잡음과 구별되지 않습니다.

비교	평균차	95% 구간	부호검정	판정
설명 빼기 (3−1)	+0.024	[−0.023, +0.071]	p=0.33	구분 안 됨
SigLIP 빼기 (2−1)	−0.014	[−0.044, +0.016]	p=0.77	구분 안 됨
자막 빼기 (4−1)	+0.006	[−0.037, +0.053]	p=0.79	구분 안 됨
음성 빼기 (5−1)	−0.012	[−0.089, +0.055]	p=0.63	구분 안 됨
그림만 vs 전부 (15−1)	**−0.262**	**[−0.366, −0.153]**	**p<0.001**	**유의**

지금 관측된 차이를 확인하려면 질문이 **"설명 빼기" 약 240개, "전부 vs 설명만" 약 128개** 필요합니다(유의수준 0.05 · 검정력 80%). 지금은 31개입니다.

> **그래서 "설명을 빼면 좋아진다" 고 말하면 안 됩니다.** 지금 말할 수 있는 것은 **"설명을 빼도 나빠지지 않았다"** 까지입니다. 이것만으로도 ★ 질문의 답은 됩니다 — **Gemini 캡션 없이 로컬 모델만으로 성능이 떨어지지 않습니다.**

유형별로 보면 방향이 정반대인 쌍이 유의합니다

유형	전부	자막만	차이	95% 구간	n	판정
재료·분량	0.713	**0.853**※	**+0.140**	[+0.004, +0.272]	12	**유의**
순서·타이밍	0.772	0.695※	−0.077	[−0.215, +0.065]	10	구분 안 됨
시각적 상태	**0.884**	0.694※	**−0.191**	[−0.371, −0.036]	9	**유의**

※ 자막+그림 조건(10번). 자막 단독(13번)도 같은 방향입니다(0.819 / 0.676 / 0.688).

- **재료·분량 질문은 자막 위주로 가는 쪽이 더 정확합니다.** 분량(`300g` , `2큰술`)은 화면 자막에 글자로 박혀 있는데, 거기에 음성과 장면 설명을 섞으면 **오히려 흐려집니다.**
- **시각적 상태 질문은 정반대로, 자막 위주로 가면 크게 떨어집니다.** 색·익은 정도는 자막에 안 적혀 있고 설명이 갖고 있습니다(설명만 조건의 시각적 상태 0.871 — 이 유형에서만 유독 높습니다).
- **전체 평균에서 이 둘이 서로 상쇄돼 0 에 가까워집니다.** 평균만 봤으면 "신호를 섞어도 별 차이 없다" 는 잘못된 결론에 도달했을 것입니다.

여기서 나오는 다음 수

1. **질의 유형별로 텍스트 소스 가중치를 다르게** 준다. 지금 `WEIGHTS` 는 질의 유형별로 갈리지만 축이 *글좌표/단어/그림* 이라, **음성·자막·설명을 따로 조절할 수 없습니다.** 색인이 셋을 한 덩어리로 합쳐 버리기 때문입니다(`search_text()`). 소스별로 좌표를 나눠 저장해야 이 실험 결과를 제품에 반영할 수 있습니다
2. **SigLIP 의 위치를 다시 잡는다.** 영상 내 순간 찾기에는 거의 기여하지 않으므로, **"어느 영상인지 찾기"(영상 전체 검색)** 로 역할을 옮기는 것이 맞아 보입니다. 거기서는 현준 님 실측(0.658)이 뒷받침합니다
3. **질문을 늘린다.** 유형당 9~12개로는 유형 간 차이만 겨우 잡히고 조건 간 차이는 못 잡습니다
4. 캡션 5개를 채워 **18개 영상 / 48질문으로 다시** 돌린다

덤으로 찾은 것 — 평가가 Gemini 를 쓰고 있었다

`search()` 의 `with_answer` 기본값이 `True` 라, `tools.eval_search` 를 한 번 돌릴 때마다 **질문 수만큼 Gemini 답변 생성**이 돌았습니다. 평가에는 쓰지도 않는 값입니다. 할당량이 자꾸 모자랐던 원인 중 하나입니다. 제거법은 `with_answer=False` 로 **Gemini 0회**입니다.

자문 3번의 출발점 — 손대기 전 0/12

정답이 없는 질문 12개 **전부에서 결과를 내놓았습니다**(평균 1위 점수 0.70). 점수 정규화가 1등을 항상 1.0 으로 만들어 "자신 없음" 을 표현할 수 없었기 때문입니다. **→ 지금은 해결했습니다(5-6장).**

> `tools.eval_search` 는 지금도 "12/12 가 결과를 내놓음" 으로 찍힙니다. **그게 맞습니다** — 자문 3을 **완전 거절이 아니라 경고**로 구현했기 때문입니다. 결과는 그대로 보여주고 `low_confidence` 만 세웁니다. 거절 성능은 `tools.threshold_sweep` 으로 따로 봅니다.

자문 3번을 실제로 풀려면 — 신호별로 재본 결과 (2026-10-12)

이건 순위 문제가 아니라 분류 문제입니다. "어떤 장면이 제일 맞나"(순위)와 "답할 자격이 있나"(거절)는 별개인데, 지금 시스템에는 후자가 아예 없습니다.

평가셋 질문으로 신호마다 1위 값을 재봤습니다(정답 있음 48개 / 정답 없음 12개).

신호	정답 있음	정답 없음	쓸 수 있나
화면에 나오는 `score`	—	—	**못 씀.** 엉뚱한 질문도 1위가 1.00
`score_dense` (정규화됨)	0.957	0.969	**못 씀.** 방향이 반대
`score_lexical`	0.380	0.255	약함. 정답 있는 질문도 **19/48 이 0**
`score_image`	0.826	0.683	약함
정규화 전 코사인	**0.587**	**0.509**	**최선. 그래도 겹침**

정규화된 값이 전부 쓸모없는 이유는 같습니다 — **"후보 중 최고 = 1.0" 으로 다시 계산**하기 때문에, 고를 게 없어도 1위는 만점이 됩니다(실측: "자동차 엔진 오일 교환하는 장면" → 1위 1.00).

`score_lexical` 은 기대했지만 아니었습니다. "맛술은 얼마나 넣어?" 처럼 없는 단어를 물으면 0 이 되지만, **정답이 있는 질문의 40% 도 0** 입니다(말로만 나오고 글자로는 안 적힌 경우).

정규화 전 코사인으로 임계값을 걸면:

임계값	올바른 거절	잘못된 거절
0.52	7/12	6/48
0.54	9/12	8/48
0.58	12/12	20/48

거절해야 할 질문은 두 종류이고, 난이도가 다릅니다

유형	예	1위 원유사도	난이도
(가) 분야가 아예 다름	"자동차 엔진 오일 교환하는 장면"	0.386~0.462	**쉬움.** 잘 갈림
(나) 맞는 영상인데 그 장면만 없음	"맛술은 얼마나 넣어?"	0.385~0.577	**어려움.** 겹침

지금 평가셋의 "정답 없음" 13개가 전부 (나) 유형입니다. 둘을 섞어 하나의 숫자로 보고하면 "어느 쪽을 해결한 것이냐"는 질문에 답할 수 없습니다. 나눠서 보고해야 합니다.

할 일 순서

1. **측정 틀을 만든다 (비용 0).** 지금 평가 스크립트는 "몇 개가 결과를 냈나" 만 세서 항상 12/12 입니다. 필요한 것은 **임계값 곡선**(올바른 거절 vs 잘못된 거절)이고, 지표도 nDCG 가 아니라 **정밀도·재현율** 입니다. **정답 없는 질문 13개로 지금 바로 할 수 있습니다** — 계획했던 5~8개를 이미 넘겼습니다. 13개라 구간이 넓은 것은 결과에 한계로 적으면 되고, 하지 못할 이유가 아닙니다. 나중에 (가)·(나) 유형을 나눠 더 받으면 더 좋아집니다
2. **정규화 전 유사도를 응답에 싣는다.** `vectors.search()` 가 Qdrant 에서 받은 원래 점수를 버리고 있습니다. `top_raw` 로 함께 내보내면 (가) 유형은 거의 다 잡힙니다
3. **임계값을 데이터로 정한다.** 그 전에 **어느 실수가 더 나쁜지**를 정해야 합니다 — 잘못 거절(있는데 없다고 함) vs 잘못 답함(엉뚱한 장면). 심사 데모라면 **보수적으로** (거절을 적게) 가는 쪽이 안전합니다
4. **(나) 유형 보강** — 둘 중 먼저 쌀 것부터

- **질의별 분포 보정(z-점수)**: 절대값 대신 그 영상 카드 전체의 평균·표준편차에서 1위가 얼마나 튀는지를 봅니다. 이미 모든 카드를 검색하므로 **추가 비용 거의 0**
- **Gemini 에게 판정을 맡김**: `ANSWER_PROMPT` 에 이미 "모르면 '저장된 장면에서는 확인되지 않습니다' 라고 해" 가 들어 있습니다. 답변이 그 문장을 내면 장면 목록을 감추면 됩니다. **호출 추가 0회**(이미 부르고 있음). 단점은 하루 20회 제한과 비결정성. **지금 얼마나 맞히는지는 아직 안 쟀습니다 — 1단계에서 같이 재세요**
- 교차 인코더 재순위는 정확하지만 무겁고 졸작 범위를 넘습니다

5. **화면 문구를 정한다.** 완전 거절("관련 장면 없음") vs 경고 + 결과("확실하지 않습니다"). **후자를 권합니다** — 잘못 거절했을 때 피해가 작습니다. 다만 자문이 "근거가 부족하면 없다고 답하라" 였으므로 **최소한 문구는 바뀌어야** 반영했다고 말할 수 있습니다

> **가장 중요한 것은 질문을 더 모으는 것이고, 그건 코드가 아닙니다.** 13개로는 무엇을 해도 좋아졌다고 말할 수 없습니다 — 제거법에서 겪은 것과 같은 문제입니다. 팀원들에게 **"정답이 없는 질문"을 각자 5~8개씩**, (가)·(나) 두 종류로 나눠 받으세요.

참고 — 2026-10-12 에 넣은 것은 보기 정리이지 이 해결책이 아닙니다

검색 결과에서 1위 점수의 25% 미만인 영상을 "관련도 낮은 결과 N개 더 보기" 뒤로 접었습니다(`sidepanel.js`). 꼬리의 잡음은 줄지만, 비율로 자르는 방식이라 **엉뚱한 질문에는 효과가 없습니다** — "자동차 엔진 오일" 질문은 이 수정 뒤에도 요리 영상 3개를 내놓습니다. 자문 3번은 여전히 미해결입니다.

기준선 — 제목·설명 기준선을 뺀 이유

멘토는 기준선 두 가지를 지목했습니다. 둘 다 구현했지만 **제목 기준선은 이 평가 설계에서 성립하지 않습니다.** 평가셋은 질문마다 정답 영상이 정해져 있어 **그 영상 안에서만** 검색하는데, 한 영상의 장면 카드는 **제목이 전부 같습니다.** 제목만으로 순위를 매기면 모든 카드의 점수가 같아져 재정렬이 일어나지 않고, 결과가 현행과 글자 그대로 같아집니다 (실측 0.747 vs 0.747, 10/10 기준).

제목이 변별력을 갖는 것은 **"어느 영상인지 찾기"**(영상 전체 검색)에서입니다. 주 비교에서 빼되 코드는 `--with-title-baseline` 으로 남겼습니다.

5-3. 처리 시간·비용 실측 (자문 4번)

`tools/cost_report.py` · 영상 18개 · 2026-10-26 재집계

새로 재지 않았습니다. `analyze.py` 가 단계마다 `timings` 를 찍어 `condition_runs` 에 저장하고 있었는데 집계하는 도구가 없었습니다.

> **2026-10-26** — 같은 일을 하던 도구가 둘(`cost_report.py` · `timings.py`)이었고 **분모가 달라 비중이 81.2% / 82.4% 로 어긋났습니다.** 하나로 합치고, 단계 합과 전체 시간의 차이를 **"기타(미기록)"** 로 드러냈습니다. 아래 표가 통일된 값입니다. 호출 수도 `analysis_health.caption` 에 성공·실패까지 들어 있었습니다.

	평균	최소	최대
영상 길이	47.2초	15	119
서버 처리	**111.7초**	51.2	272.3
사용자 대기 (캡처 + 서버)	**158.9초**		

단계별 (서버 처리 111.7초의 구성):

단계	평균	비중
음성 (faster-whisper)	13.7초	12.3%
프레임 (EasyOCR + Gemini 설명)	**90.8초**	**81.2%**
좌표 (BGE-M3 + SigLIP2)	5.6초	5.0%
기타 (단계로 기록 안 된 자투리)	1.6초	1.5%

서버 처리가 영상 길이의 평균 2.4배입니다. 그리고 그중 **81%가 프레임 단계**(자막 OCR + 장면 설명)입니다. 서비스화할 때 먼저 손봐야 할 곳이 어디인지가 숫자로 나옵니다 — 멘토가 지적한 "저장 영상 전체의 프레임에 캡션을 생성하는 구조" 가 정확히 이 82%입니다.

> **사용자가 기다리는 157초 중 캡처는 30%(47초)뿐입니다.** 나머지 70%는 업로드 후 서버가 도는 시간이고, 그동안 사용자는 이미 자리를 떠도 됩니다. 저장 UX를 고칠 때 캡처만 손대면 체감의 1/3밖에 못 줄입니다.

비용 — 돈이 아니라 처리량이 제약입니다

실제 지출	**0원** (무료 티어)
영상당 Gemini 호출	**1회** (장면 설명). `MAX_GEMINI_CALLS_PER_VIDEO` 로 코드가 강제
무료 티어 한도	모델당 **하루 20회**
하루 처리 가능 영상	**20개**

측정 당시 성공 13회 / 실패 5회였고, **실패 5회는 전부 그날 할당량 소진**입니다. 그래서 5개 영상에 장면 설명이 없습니다(6장).

단가를 곱한 금액은 적지 않았습니다 — 무료 티어라 지출이 0이고, 단가는 바뀌며 우리가 확인할 수 없는 값이기 때문입니다. **이 프로젝트에서 실제로 부딪힌 벽은 돈이 아니라 하루 20회였고**, 그래서 영상당 호출을 4회에서 1회로 줄였습니다. 그 사건 자체가 자문 4가 요구한 근거 자료입니다.

이 숫자를 읽을 때

- **CPU 전용, 노트북 한 대, 각 영상 1회 측정**입니다. 반복 측정이나 GPU 비교는 없습니다
- 장면 설명이 실패한 영상 5개는 재시도 시간이 프레임 단계에 포함돼 있습니다 (그 5개만의 프레임 평균 89.3초로 전체 평균 90.8초와 거의 같아, 큰 왜곡은 아닙니다)
- `l3WthBEFzFw` 는 프레임 단계가 231.7초로 유독 깁니다. 원인 미확인

5-4. 저작권·이용약관 범위 (자문 5번)

> 멘토: 외부 플랫폼 콘텐츠의 추출·저장은 서비스화 시 약관 검토가 필요하므로, **현재 범위(개인 학습·연구 목적)를 발표 자료에 명시**할 것.

발표 자료와 README 에 그대로 넣을 문단입니다.

> 이 시스템은 **개인 학습·연구 목적의 졸업작품**이며 상용 서비스가 아닙니다.
>
> 설계상 **서버는 유튜브에 한 번도 접속하지 않습니다.** 영상 파일을 내려받지 않고, 사용자가 **자신의 브라우저에서 이미 재생 중인 화면**을 확장 프로그램이 캡처해 올립니다. 저장되는 것은 원본 영상이 아니라 **0.5초 간격 정지 이미지와 그로부터 추출한 텍스트(자막·음성 전사·장면 설명)** 이며, 검색 결과는 영상을 재생해 주는 것이 아니라 **유튜브의 해당 시점으로 이동**시킵니다. 재생은 항상 유튜브에서 일어납니다.
>
> 따라서 `yt-dlp` 같은 영상 파일 다운로드와는 성격이 다릅니다. 다만 **외부 플랫폼 콘텐츠를 가공·보관한다는 점은 동일하므로, 서비스화한다면 유튜브 이용약관 검토가 선행되어야 합니다.** 현재 데이터는 전부 사용자 로컬(`data/`)에만 저장되며 외부로 공유되지 않습니다.

이 주장을 뒷받침하는 설계 원칙은 `CLAUDE.md` 의 **설계 원칙 1** 로 코드에 강제돼 있습니다 — "서버는 유튜브에 접속하지 않는다. 프레임·오디오는 확장이 브라우저에서 뽑아 올린다."

5-5. 의미 단위 병합 — 해보고 채택하지 않았습니다 (자문 1번)

`server/pipeline/segmenter.py` 의 `merge_segments()` · 실험 `tools/merge_experiment.py` · 원자료 `eval/merge_experiment.json`

> 멘토: 4초 고정 분할은 '재료를 볶는다', '불을 줄인다' 같은 의미 단위와 경계가 어긋나 하나의 행위가 여러 조각으로 흩어진다. **고정 분할을 기준선으로 두고, 인접 세그먼트를 의미 단위로 병합하는 후처리를 추가**할 것.

먼저 — 문제가 지적보다 나쁜 형태였습니다

병합 규칙을 감으로 정하지 않으려고 저장된 18개 영상의 **인접 카드 147쌍**을 먼저 쟀습니다. 말 토큰 자카드가 **1.00(= 글자 그대로 같음)** 인 쌍이 실제로 나왔습니다.

```
[Zlo2JQzihwc 60s] 자카드 1.00
    줌이 끓여주고
    줌이 끓여주고
```

`_spans_in_window` 는 창에 **걸치기만 해도** 그 발화를 통째로 넣습니다. 그래서 10초짜리 발화 하나가 4초 카드 3장에 **복사**됩니다. "흩어진다" 가 실제로는 **같은 말의 중복**으로 나타나고 있었습니다. 그래서 병합 기준을 **포함도**(짧은 쪽 토큰이 긴 쪽에 얼마나 들어 있나)로 잡았습니다 — 자카드는 길이 차이 때문에 이 모양을 낮게 봅니다.

고정 분할은 없애지 않았습니다. 멘토가 "기준선으로 두고" 라고 명시했고, `merge_segments(similarity=0)` 이면 후처리가 아무것도 하지 않아 예전과 같습니다.

결과 — 합칠수록 나빠집니다

영상 18개 / 질문 48개. 재분석 없음(저장된 카드를 합쳐 다시 색인만), **Gemini 호출 0회.**

임계값	장면 카드	nDCG@5	기준대비	Recall@5
0 (고정 분할)	203	**0.756**	—	0.812
0.50	158	0.685	**−0.071**	0.729
0.60	175	0.707	−0.049	0.750
0.70	184	0.741	−0.016	0.781
0.80	189	0.748	−0.008	0.802
0.90	191	0.748	−0.008	0.802

임계값 5개에서 단조롭게 나빠집니다. 짝지은 부트스트랩으로 t=0.50 은 95% 구간 [−0.146, −0.002], t=0.60 은 [−0.105, −0.004] 로 0 을 벗어납니다. 다만 부호검정은 유의하지 않습니다(p=0.33, 0.09) — 질문 몇 개에서 크게 깎인 것이 평균을 끌어내린 형태입니다. **방향은 분명하지만 크기는 조심해서 말해야 합니다.**

왜 나빠졌나 — 검색은 좋아졌고 이동 지점이 뭉툭해졌습니다

"못 찾아서" 인지 "찾았는데 엉뚱한 데로 보내서" 인지를 갈라 봤습니다. 허용 오차를 무시하고 **정답 시각을 품은 카드를 가져왔는지**만 따로 셌습니다.

임계값	카드 길이	정답 품은 카드를 가져옴	시점 오차	nDCG@5
0 (고정 분할)	4.0초	65/94 (69%)	2.8초	**0.756**
0.50	5.4초	**73/94 (78%)**	**3.5초**	0.685
0.70	4.5초	70/94 (74%)	3.1초	0.741
0.90	4.4초	68/94 (72%)	3.0초	0.748

멘토의 가설은 맞았습니다. 의미 단위로 합치면 정답을 품은 카드를 **9%p 더 많이** 찾아옵니다(69% → 78%). 조각나 있던 행위가 한 장으로 모이니 검색이 쉬워집니다.

그런데 이 제품의 가치는 "그 초로 데려다주는 것"입니다. 카드가 길어지면 이동 지점이 앞으로 밀려(2.8초 → 3.5초) 사용자가 더 기다려야 합니다. 평가의 비대칭 허용 오차가 바로 그 손해를 재는 장치이고, **검색이 좋아진 이득보다 이 손해가 큽니다.**

다음 수까지 시험했습니다 — 검색은 병합 카드로, 이동은 4초 조각으로

위 표를 보면 당연한 수가 떠오릅니다. 검색의 이득(+9%p)은 가지고 이동의 손해만 없애면 됩니다. 병합 카드가 **합치기 전 4초 조각을 기억**하게 하고(`parts`), 결과를 줄 때 그 안에서 질의에 맞는 조각으로 보내면 됩니다(`search.localize_seek`). 구현해서 쟀습니다.

임계값	이동 지점	nDCG@5	기준대비
0 (고정 분할)	—	**0.756**	—
0.50	카드 맨 앞	0.685	−0.071
0.50	**조각으로 이동**	0.700	−0.056
0.60	조각으로 이동	0.707	−0.049
0.70	조각으로 이동	0.741	−0.016

일부만 회복하고 끝났습니다(0.685 → 0.700). 0.60 이상에서는 아예 변화가 없습니다 — 조각을 고르는 근거가 질의 단어인데, **정답이 있는 질문의 40% 는 단어 점수가 0** 이라 고를 수가 없습니다(5-2장에서 이미 측정한 값입니다).

그래서 천장을 쟀습니다 — 고르기를 아무리 잘해도 안 됩니다

"고르는 방법이 나빠서인가"를 가리려고 **정답 위치를 보고 조각을 고르는 치트**(오라클)로 상한을 쟀습니다.

임계값	단어로 고르기	오라클(천장)
0.50	0.700	**0.716**
0.60	0.707	**0.730**
0.70	0.741	**0.757**
—	고정 분할 **0.756**	

천장이 기준선 아래입니다. 0.70 에서 겨우 동률인데 그때는 카드의 9% 만 합쳐집니다. → **이동 지점을 고르는 방법을 아무리 개선해도(임베딩 등) 이득이 없습니다.** 더 만들 이유가 없다는 것이 확인됐습니다.

왜 그런지도 분명합니다. 합치면 카드 수가 줄어(203 → 158) **상위 5개로 짚을 수 있는 서로 다른 정답이 줄어듭니다.** Recall@5 가 0.812 → 0.740 으로 떨어지는 것이 그 자국입니다. 짧은 카드 203장이 긴 카드 158장보다 더 많은 정답을 가리킵니다.

결론 — 고정 분할을 유지합니다

멘토의 진단(4초 분할이 의미 단위를 쪼갠다)은 **맞았고**, 병합하면 **검색은 실제로 좋아집니다** (정답 품은 카드 69% → 78%). 그러나 이 제품의 지표는 "맞는 장면을 top-5 안에 **몇 개나, 얼마나 정확한 시점으로**" 이고, 거기서는 **고정 분할이 더 낫습니다.** 천장까지 재서 확인했습니다.

코드는 남깁니다 — `merge_segments()`, `parts`, `localize_seek()` 모두 기본값이 꺼짐 (`MERGE_SIMILARITY=0`)이라 제품 동작은 고정 분할 그대로입니다. 지우지 않는 이유는 **"안 해봤다" 가 아니라 "해보고, 구제책까지 해보고, 천장까지 재서 안 된다는 것을 안다"** 가 보고할 내용이기 때문입니다. SigLIP2 파인튜닝(4장)과 같은 모양입니다.

5-6. "관련 장면 없음" — 구현하고 운영점을 데이터로 골랐습니다 (자문 3번)

`server/search.py` · `config.NO_ANSWER_THRESHOLD` · 실험 `tools/threshold_sweep.py` · 원자료 `eval/threshold_20261026.json`

> 로직이 어떻게 도는지는 **`abstention.md`** 에 따로 정리돼 있습니다(박현준).

> 멘토: 근거가 부족하면 **"관련 장면 없음"** 이라고 답할 것.

무엇이 막고 있었나

`hybrid_search` 가 Qdrant 에서 받은 **정규화 전 코사인 값을 혼합 점수로 덮어쓰고** 있었습니다. 그런데 정규화(minmax)는 후보 중 최고를 **항상 1.0** 으로 만듭니다. 그래서 아무것도 안 맞는 질의에서도 1위가 만점이 되고, "자신 없음" 을 표현할 방법이 없었습니다. → `score_raw` 로 보존하고 응답에 `top_raw` 를 실었습니다.

거절해야 할 질문은 두 종류이고, 난이도가 다릅니다

유형	예	n	1위 원유사도
정답 있음	—	48	평균 **0.587** (0.432~0.683)
(나) 맞는 영상인데 그 장면만 없음	"맛술은 얼마나 넣어?"	12	평균 **0.509** (0.385~0.577)
(가) 분야가 아예 다름	"자동차 엔진 오일 교환"	10	평균 **0.443** (0.386~0.506)

판별력 AUC — (가) 0.967 / (나) 0.838 (0.5 = 신호 없음, 1.0 = 완벽히 갈림).

(나) 가 어려운 것은 당연합니다. 요리 영상에 요리 질문이라 **의미적으로는 가깝고** 그 장면만 없기 때문입니다.

> (가) 질의 10개는 `eval/offtopic.txt` 에 있고 **팀이 작성했습니다.** 평가셋 질문은 팀 외부 지인에게 받았지만 이것은 다릅니다 — 요리 보관함에 자동차 질문의 답이 없다는 것은 라벨링 판단이 필요 없는 자명한 사실이라 성격이 다르고, 그래서 **섞지 않고 따로** 보고합니다.

임계값 곡선 — 운영점 0.52

임계값	(가) 올바른 거절	(나) 올바른 거절	잘못된 거절
0.48	8/10	2/12	3/48
0.50	9/10	5/12	5/48
0.52	**10/10**	**7/12**	**6/48**
0.54	10/10	9/12	8/48
0.58	10/10	12/12	**20/48**

0.58 까지 올리면 거절해야 할 것을 전부 잡지만 **답이 있는 질문의 42% 를 같이 버립니다.** 0.52 를 골랐습니다 — **분야가 다른 질문은 전부 잡고**, 장면만 없는 경우는 58% 를 잡으면서, 잘못된 거절이 12.5% 입니다.

완전 거절이 아니라 경고입니다

결과를 감추지 않고 `low_confidence` 만 세웁니다. 화면에는 이렇게 뜹니다:

> 저장된 장면 중에 확실히 맞는 것을 찾지 못했습니다. 아래는 그나마 가까운 결과입니다.

감추면 잘못 걸린 6개를 영영 못 보게 되지만, 경고로 두면 피해가 "불필요한 한 줄" 로 끝납니다. 그래서 임계값을 조금 공격적으로 잡을 수 있었습니다. 심사 데모에서 멀쩡한 질문을 거절하는 쪽이 더 치명적이라는 판단입니다.

실제 동작 확인

질문	`top_raw`	경고
감자조림 영상에 파 넣는 장면 찾아줘	0.555	—
간장 넣는 장면 찾아줘	0.606	—
김치찜 만드는 영상 찾아줘	0.635	—
자동차 엔진 오일 교환하는 장면	0.462	**경고**
주식 차트 보는 장면 찾아줘	0.420	**경고**
강아지 산책시키는 장면	0.399	**경고**

자문 3번 성적이 0/12 에서 (가) 10/10 · (나) 7/12 로 바뀌었습니다.

한계

- **(나) 가 12개뿐입니다.** 7/12 의 신뢰구간은 넓습니다. 이 유형의 질문을 더 받으면 운영점을 더 정확히 고를 수 있습니다
- (가) 질의는 팀이 썼습니다(위 설명)
- 임계값은 `.env` 의 `NO_ANSWER_THRESHOLD` 한 줄로 조절하거나 `0` 으로 끌 수 있습니다

5-7. 사용자 평가 결과 (자문 7번 · 2차 자문 마지막 항목)

원자료 `eval/user_study_raw.csv` · 설계 `docs/user-study.md` · 2026-10-26 진행

참가자 **10명**, 1인당 과제 6개(조건당 3개씩), 총 60과제. 진행자 임준서·박현준·이동현·이태연.

조건	하는 일
A	유튜브에서 **직접 스크롤**해 찾기 (지금 방식)
B	사이드패널 검색창에 **자기 말로** 물어보기 (제안 시스템)

결론 — 시간이 2.9배 빨라졌습니다

	A 직접 찾기	B 제안 시스템
평균 소요 시간	27.3초	**9.3초**
중앙값	27.3초	8.5초
표준편차	6.6초	5.1초
평균 시도 횟수	1.56회	**1.10회**

참가자 10명 전원에서 제안 시스템이 더 빨랐습니다(54%~80% 단축). **부호검정 p = 0.0020.**

참가자	A	B	단축
P01	34.7초	7.0초	80%
P02	27.3초	8.7초	68%
P03	23.5초	7.8초	67%
P04	24.0초	10.4초	57%
P05	24.3초	6.7초	73%
P06	25.3초	8.0초	68%
P07	27.0초	12.3초	54%
P08	24.3초	9.0초	63%
P09	34.3초	15.3초	55%
P10	28.3초	7.7초	73%

성공률은 양쪽 다 높아 변별력이 없습니다

기준	A	B
사전에 정한 기준 (정답 시작 −5초 ~ +2초)	28/30 (93%)	25/30 (83%)
대안 기준 (정답 구간 전체 −5초 ~ +2초)	30/30 (100%)	29/30 (97%)

두 기준을 모두 적는 이유 — 사전 기준으로는 B 가 더 낮게 나오는데, **실패 7건 중 6건이 "정답 구간 안에 도달했는데 기준에서 벗어난" 경우**였습니다.

과제	정답 구간	길이	사전 기준 인정 범위
T1	35~41초	**6.0초**	30~37초 ← 38~41초가 빠짐
T2	22~33초	**11.0초**	17~24초 ← 25~33초가 빠짐
T3~T6	—	2~3.9초	문제 없음

사전 기준은 **정답 구간이 짧다는 전제**(자동 평가의 4초 카드)로 만든 것인데, **T1·T2 를 과제로 고를 때 구간 길이를 안 봤습니다. 제 선정 실수입니다.** 결과를 보고 기준을 바꾼 것이 아니라 **과제 정의만 봐도 알 수 있던 문제**라, 숨기지 않고 두 수치를 함께 적습니다.

진짜 실패는 1건뿐입니다 — P04 의 T5(떡 넣는 순간, 정답 31~34초)에서 12초로 이동했습니다. 3.1초 만에 첫 결과를 눌렀고 그게 틀렸습니다.

> **성공률로는 두 방식을 가를 수 없습니다.** 둘 다 천장(93~100%)에 붙었습니다. 과제가 "저장된 영상 안에서 찾기" 라 직접 스크롤해도 1분 안에는 찾아집니다. **변별력은 시간에 있습니다.**

유형별

유형	A 시간	B 시간	단축	A 성공	B 성공
재료·분량	27.7초	8.0초	**71%**	10/10	10/10
순서·타이밍	30.1초	7.1초	**76%**	10/10	9/10
시각적 상태	24.1초	12.7초	47%	10/10	10/10

시각적 상태만 단축폭이 작습니다(47%). 검색으로 찾아도 "어느 정도 익었나" 같은 것은 사람이 몇 초 더 보며 확인하기 때문으로 보입니다.

서비스 가능성 — 비용과 효용을 나란히

> 영상 1건을 저장하는 데 **캡처 47초 + 서버 처리 112초**가 들고, 무료 티어에서는 **하루 20건**이 한계다(**비용**, 5-3장). 그 대가로 사용자는 저장된 영상에서 원하는 장면을 찾는 데 걸리는 시간이 **27.3초에서 9.3초로 66% 줄었고**(**효용**), **참가자 10명 전원**에서 같은 방향의 개선이 관찰되었다(부호검정 p=0.002).

한계

- **n=10** 입니다. 시간 차이는 10/10 으로 일관되지만, 성공률은 양쪽 다 천장이라 비교가 성립하지 않습니다
- **과제 선정에 실수가 있었습니다**(T1·T2 의 정답 구간 길이). 위에 그대로 적었습니다
- 진행자가 4명이라 안내 말투가 완전히 같지는 않았을 수 있습니다
- P08 의 A 조건 3건은 **시도 횟수가 기록되지 않았습니다**
- 참가자가 쓴 **질의문 30개는 그대로 남겨 두었습니다**(`eval/user_study_raw.csv`). 실제 사용자 말투라 다음 평가셋 질문 재료입니다

참가자가 남긴 말

> "검색 결과로 나온 시간을 클릭하면 바로 이동하는 기능이 있었으면 좋겠다" (P09) → **이미 있는 기능입니다.** 영상 드롭다운을 펼치면 나오는데 **찾지 못했습니다.** 발견 가능성(discoverability) 문제입니다

> "굳이 없었다" (P10)

---

6. 지금 숫자를 그대로 쓰면 안 되는 이유

항목	내용
설명 채움률 81%	2026-10-21 에 채웠습니다. 다만 `GRID_FRAMES(12) × 호출(1)` 상한 때문에 **100% 는 설계상 불가능**하고 82% 가 천장입니다. 장면이 12개 넘는 영상 9개가 구조적으로 못 채워집니다
표본이 얇다	유형당 13~19개. 유형 간 차이를 주장하기엔 적습니다
질문 4개 사용 불가	팀원 한 명이 담당 영상 대신 본인 테스트 영상으로 질문을 만들었고, 그 영상이 공용 색인에 없습니다
라벨러 일치도(κ) 없음	담당을 영상별로 나눠 같은 질문을 두 사람이 라벨링한 경우가 0건입니다. 질문을 외부에 의뢰해 자문 5번의 "또는" 조건은 충족하지만 κ 는 낼 수 없습니다
번역 캐시	같은 조건으로 두 번 돌렸을 때 48개 중 1개의 점수가 달라졌습니다. 질의 번역이 캐시에 없어 새로 번역된 탓입니다. 캐시가 찬 뒤부터 고정됩니다 — **개선 전후를 비교하기 전에 한 번 돌려 캐시를 채워야 합니다**

---

7. 다음

멘토 자문(1차·2차)이 요구한 항목은 전부 처리됐습니다. 남은 것은 아래입니다.

1. **추진 일정표 · 역할 분담표 — 초안 작성 완료** (`docs/plan-and-roles.pdf`). 지난 일정은 git 이력에서 뽑은 사실이고, **역할 분담표의 담당자 칸만 비어 있습니다.** 팀이 이름을 채우고 11월 이후 날짜를 최종 평가 일정에 맞추면 됩니다
2. **시각적 상태 질문 보강 — 장면 설명(Gemini)을 끌지 말지가 여기 달렸습니다**(5-2장). 끄면 파이프라인이 100% 로컬이 되고 하루 20건 한도가 사라집니다. 지금 질문이 13개뿐이라 "설명을 빼면 시각적 상태가 나빠진다" 가 확정되지 않았습니다

3. **(나) 유형 질문 보강** — 자문 3의 거절 임계값을 12개로 골랐습니다(5-6장). "맞는 영상인데 그 장면만 없는" 질문을 더 받으면 운영점이 정확해집니다
4. **사용자 평가에서 나온 질의문 30개를 평가셋에 반영** — 실제 사용자 말투입니다 (`eval/user_study_raw.csv`). 지금 평가셋 질문보다 짧고 구어체입니다
5. **발견 가능성 개선** — P09 가 "시간을 클릭하면 바로 이동했으면" 이라고 했는데 **이미 있는 기능**입니다. 드롭다운 안에 있어 못 찾았습니다
6. **질문 4개 처리** — 본인 테스트 영상이 공용 색인의 김치찜과 같은 영상인지 확인
7. **소스별 좌표 분리** (5-2장 결과를 제품에 반영) · **SigLIP 역할 재배치** — 둘 다 구조 변경이라 남은 일정과 견줘 판단하세요

부록 — 문서 지도

지금 보는 것	용도
`docs/PROGRESS.md`	**이 문서.** 자문 이후 진행 상황 전체
`docs/summary.pdf`	**제출용 요약 4쪽** — 이 문서를 추린 것
`docs/plan-and-roles.md` · `.pdf`	추진 일정표 · 역할 분담표 (제출용)
`README.md`	설치·실행법, 코드 구조
`docs/eval-guide.md`	질문·라벨링 작업 지침
`CLAUDE.md`	Claude Code 작업 지침

세부 기록 (필요할 때만)	
`docs/abstention.md`	"관련 장면 없음" 구현 상세 (5-6장 보충)
`docs/user-study.md` · `user-study-guide.pdf`	사용자 평가 설계 근거 · 진행 안내서 (5-7장 보충)
`docs/fixes-20261005.md`	박현준 10/05 수정 상세 (3장 보충)
`docs/fixes-20261010.md`	이동현 10/09~10 수정 상세 (3장 보충)
`SigLIP2_실험기록_20260914.md`	SigLIP2 실험 전문 (4장 보충)
`docs/mentor-feedback.md`	9/18 자문 원문
`eval/video_list.md`	저장된 영상 18개

측정 원자료	
`eval/result_20261021.json`	공식 기준선 (5장)
`eval/ablation.json`	제거법 15조건 (5-2장)
`eval/merge_experiment.json`	의미 단위 병합 (5-5장)
`eval/threshold_20261026.json`	거절 임계값 곡선 (5-6장)
`eval/user_study_raw.csv`	사용자 평가 60과제 (5-7장)

> **낡은 문서는 `docs/archive/` 로 옮겼습니다.** 지우지 않은 이유와 그중 아직 쓸 만한 부분은 그 폴더의 README 에 적어 두었습니다.