멀티모달 RAG 기반 지능형 비디오 검색 시스템

다 찾아드림 · 진행 상황 요약 · 2026-10-26

상세 근거와 측정 원자료는 docs/PROGRESS.md(963줄)에 있습니다.

1. 한 줄 요약

> 유튜브 쇼츠를 저장해 **4초 장면 카드**로 분석해 두고, 자연어로 물으면 **그 초로 이동**시키는 시스템입니다. 사용자 평가에서 장면 찾기에 걸리는 시간이 **27.3초 → 9.3초(66% 단축)**로 줄었고, 참가자 **10명 전원**에서 같은 방향의 개선이 관찰되었습니다(부호검정 p=0.002).

2. 정량 성과

항목	결과
사용자 과제 소요 시간	**27.3초 → 9.3초 (66% 단축)** · 참가자 10/10명 개선 · p=0.002
검색 성능	**nDCG@5 0.745** · Recall@5 0.802 · mAP 0.621 · 1위적중 0.688 음성 단일 신호 기준선 대비 nDCG **+0.027** · 1위적중 **+0.063**
과제 성공률	직접 탐색 93% / 제안 시스템 83% — **양쪽 모두 천장에 근접해 변별력 없음**
처리 비용	영상 1건당 캡처 47초 + 서버 112초 · 외부 API 호출 **1회**(4회에서 감축)
평가 규모	영상 18개 · 장면 카드 203개 · 질문 64개 · 정답 라벨 113줄 · 사용자 10명
수정한 결함	16건 — **대부분 오류 없이 조용히 틀린 값을 내던 것**

3. 시스템 구성

서버는 유튜브에 한 번도 접속하지 않습니다. 사용자가 자기 브라우저에서 보고 있는 화면을 확장 프로그램이 캡처해 올립니다.

단계	쓰는 모델	비고
음성 받아적기	faster-whisper (로컬)	WhisperX 는 Python 3.14 미지원
화면 자막	EasyOCR (로컬)	장면의 94% 를 채움
장면 설명	**Gemini** (외부)	**유일한 외부 호출.** 영상당 1회
글 좌표	BGE-M3 1024차원 (로컬)	
그림 좌표	SigLIP2-naflex (로컬)	질의를 영어로 번역해 사용

검색은 **글 좌표 · 정확한 단어(IDF) · 그림 좌표** 세 신호를 질의 유형별 가중치로 합산합니다.

4. 평가 체계

질문	64개 — 팀원 4명이 각자 **팀 외부 지인**에게 받았습니다(편향 방지)
정답 라벨	113줄 — 전부 팀원이 직접 작성. 정확 2 / 관련 1 / 무관 0
정답 단위	**시간 구간(초)** — 세그먼트 번호가 아닙니다. 분할 방식을 바꿔도 평가셋을 다시 만들 필요가 없습니다
허용 오차	**비대칭** — 정답 시작의 이전 5초 ~ 이후 2초. 사용자는 목표보다 앞서 시작하는 것은 감수해도 지나쳐 시작하는 것은 감수하지 못합니다

주지표	nDCG@5. 질문 유형(재료·분량 / 순서·타이밍 / 시각적 상태)별로 분리 보고

5. 멘토 자문 대응

1차(9/18) 보완 5건과 2차(10/12) 요구가 전부 처리됐습니다. 전부 "좋아졌다" 는 아닙니다 — **해보고 채택하지 않은 것이 둘** 있고, 그 과정이 결과입니다.

자문 1 · 인접 세그먼트 의미 단위 병합 → 채택하지 않음

조건	nDCG@5	해석
고정 분할(현행)	**0.745**	기준
병합 0.50	0.685	임계값 5개에서 **단조롭게 나빠짐**
병합 0.70	0.741	

> **멘토의 진단은 맞았습니다.** 병합하면 정답을 품은 카드를 **9%p 더 많이** 찾아옵니다(69% → 78%). 그러나 카드가 길어져 **이동 지점이 뭉툭해지고** (시점 오차 2.8초 → 3.5초), 카드 수가 줄어 top-5 가 짚는 서로 다른 정답이 줄어듭니다.
> 구제책(병합 카드로 검색 + 원래 4초 조각으로 이동)도 구현해 측정했고, **정답 위치를 보고 조각을 고르는 치트(오라클)로 천장을 재도 기준선을 못 넘었습니다.** → 고정 분할을 유지합니다. 코드는 남겨 두고 기본값만 껐습니다.

자문 2 · 신호별 역할 규명 (핵심 기여)

신호 4개(음성·자막·설명·그림)의 조합 **2^4-1 = 15가지를 전수**로 측정했습니다.

조건	nDCG@5	Recall@5	mAP	1위적중	답하는 질문
전부 (현행)	0.745	0.802	0.621	0.688	기준
설명 제외	**0.772**	**0.833**	**0.660**	**0.750**	**Gemini 없이 로컬만으로 되나**
자막 제외	0.765	0.781	0.630	0.708	EasyOCR 이 필요한가
음성 제외	0.697	0.771	0.561	0.604	**음성이 가장 중요**
그림만	0.470	0.594	0.368	0.292	무작위(0.480)와 구별 안 됨

설명을 빼면 네 지표가 모두 올라갑니다 — nDCG +0.026 · Recall +0.031 · mAP +0.039 · 1위적중 +0.062. 한 지표만 좋아졌다면 지표 선택의 문제일 수 있지만, 네 개가 같은 방향이면 그렇게 보기 어렵습니다.

> **가장 중요한 발견 — 신호의 역할이 질문 유형에 따라 정반대입니다.**
> **재료·분량** 질문은 자막 위주가 유의하게 낫고(+0.084, 95% [+0.037, +0.139]), **시각적 상태**는 정반대입니다. **전체 평균에서 둘이 상쇄돼 0 에 가까워집니다.** 평균만 봤다면 "신호를 섞어도 별 차이 없다" 는 잘못된 결론에 갔을 것입니다.

> **SigLIP 단독은 무작위와 구별되지 않습니다**(0.470 vs 무작위 0.480). 같은 영상의 카드끼리는 그림이 서로 비슷해 변별이 안 됩니다. 다만 다른 신호와 함께일 때는 짝지어 뺄 때마다 4/4 모두 떨어져, 보조 신호로는 일관되게 기여합니다.

자문 3 · 근거 부족 시 "관련 장면 없음" → 해결

막고 있던 것 — 순위 점수는 min-max 정규화로 **후보 중 최고를 항상 1.0** 으로 만듭니다. 요리 보관함에 "자동차 엔진 오일 교환" 을 물어도 1위가 만점으로 나옵니다(실측). 그래서 정규화 **전** 코사인 유사도를 따로 꺼내 판정에 씁니다.

질문 종류	n	1위 원유사도 평균	판별력 AUC
정답 있음	48	0.585	—
(나) 맞는 영상인데 장면만 없음	12	0.511	0.849
(가) 분야가 아예 다름	10	0.450	**0.967**

운영점 0.52 결과	(가)	(나)	잘못된 거절
손대기 전	0/10	0/12	0/48
지금	**10/10**	**7/12**	**5/48**

> **완전 거절이 아니라 경고입니다.** 결과는 그대로 보여주고 "확실히 맞는 것을 찾지 못했습니다" 를 띄웁니다. 감추면 잘못 걸린 5건을 영영 못 보지만, 경고면 피해가 한 줄로 끝나므로 임계값을 조금 공격적으로 잡을 수 있었습니다. **잘못된 거절 5/48 을 성적과 반드시 같이 적습니다** — 빼놓으면 대가가 보이지 않습니다.

자문 4 · 처리 시간·비용 실측

항목	평균	비중
영상 길이	47.2초	
음성 받아적기	13.7초	12%
화면 자막 + 장면 설명	**90.8초**	**81%**
좌표 만들기	5.6초	5%
사용자 대기 (캡처 + 서버)	**158.9초**	캡처가 30%

> **비용은 돈이 아니라 처리량입니다.** 실제 지출 0원(무료 티어)이지만 **모델당 하루 20회** 제한이 있어 **하루 20개 영상**이 한계입니다. 개발 중 실제로 이 벽에 부딪혀 영상당 호출을 4회에서 1회로 줄였습니다. 멘토가 지적한 "저장 영상 전체의 프레임에 캡션을 생성하는 구조" 가 정확히 위 **81%** 입니다.

자문 5 · 저작권 범위

개인 학습·연구 목적의 졸업작품입니다. **서버는 유튜브에 접속하지 않고** 영상 파일을 내려받지도 않습니다. 저장되는 것은 **0.5초 간격 정지 이미지와 거기서 추출한 텍스트**이며, 검색 결과는 영상을 재생해 주는 것이 아니라 **유튜브의 해당 시점으로 이동**시킵니다. 재생은 항상 유튜브에서 일어납니다. 다만 외부 플랫폼 콘텐츠를 가공·보관한다는 점은 같으므로, **서비스화한다면 이용약관 검토가 선행되어야 합니다.**

6. 사용자 평가 (2026-10-26 · 참가자 10명 · 60과제)

조건	하는 일
A 직접 찾기	유튜브에서 **직접 스크롤**해 찾기 — 지금 사용자가 하는 행동
B 제안 시스템	검색창에 **자기 말로** 물어보기

한 사람이 두 조건을 모두 수행하고, 조건 순서와 과제 묶음 순서를 각각 5명씩 교차해 학습 효과를 상쇄했습니다. 검색어는 **참가자가 직접** 지었습니다.

	A 직접 찾기	B 제안 시스템
평균 소요 시간	27.3초	**9.3초**
중앙값	27.3초	8.5초
평균 시도 횟수	1.56회	1.10회
과제 성공률	93%	83%

참가자 10명 전원에서 제안 시스템이 더 빨랐습니다(단축폭 54~80%). **부호검정 p = 0.0020.** 유형별 단축은 순서·타이밍 76%, 재료·분량 71%, 시각적 상태 47% 입니다.

성공률로는 두 방식을 가를 수 없습니다. 양쪽 다 천장(93~100%)에 붙었습니다 — 저장된 영상 안에서 찾는 과제라 직접 스크롤해도 1분 안에 찾아집니다. **변별력은 시간에 있습니다.**

과제 선정에 실수가 있었습니다. 실패 7건 중 6건이 "정답 구간 안에 도달했는데 성공 기준에서 벗어난" 경우였습니다. 기준이 *정답 시작 −5초 ~ +2초* 인데 두 과제의 정답 구간이 6초·11초로 길어 뒤쪽에 도달하면 범위를 벗어납니다. 구간 전체를 인정하면 A 100% / B 97% 입니다. **두 수치를 모두 보고합니다.**

7. 서비스 가능성

영상 1건을 저장하는 데 **캡처 47초 + 서버 처리 112초**가 들고, 무료 티어에서는 **하루 20건**이 한계다(**비용**). 그 대가로 사용자는 저장된 영상에서 원하는 장면을 찾는 데 걸리는 시간이 **27.3초에서 9.3초로 66% 줄었고**(**효용**), **참가자 10명 전원**에서 같은 방향의 개선이 관찰되었다(p=0.002).

8. 한계 — 그대로 밝힙니다

표본이 작습니다	질문 64개, 사용자 10명. 큰 차이는 잡히지만 **작은 차이는 확정할 수 없습니다.** 유형별 질문이 13~19개라 유형 간 비교는 경향까지만 말합니다
설명 채움률 81%	**100% 는 설계상 불가능**합니다. 영상당 설명 지점이 12개로 고정이라 장면이 12개를 넘는 영상 9개는 구조적으로 못 채웁니다(천장 82%)
라벨러 일치도 없음	영상별로 담당을 나눠 같은 질문을 두 사람이 라벨링한 경우가 0건입니다. 질문을 팀 외부에 의뢰해 편향 방지 조건은 충족하지만 κ 는 낼 수 없습니다
사용자 평가 과제 선정	위 6장에 적은 정답 구간 길이 문제

9. 다음

1	**시각적 상태 질문 보강 — 장면 설명(Gemini)을 끌지 말지가 여기 달렸습니다.** 끄면 파이프라인이 100% 로컬이 되고 하루 20건 한도가 사라집니다. 지금 질문이 13개뿐이라 "설명을 빼면 시각적 상태가 나빠진다" 가 확정되지 않았습니다
2	**답 없는 질문 보강** — 거절 임계값을 12개로 골랐습니다. 더 받으면 운영점이 정확해집니다
3	**사용자 질의문 30개를 평가셋에 반영** — 실제 사용자 말투라 지금 평가셋보다 짧고 구어체입니다
4	**발견 가능성 개선** — 참가자 한 명이 "시간을 클릭하면 바로 이동했으면" 이라고 했는데 **이미 있는 기능**입니다. 드롭다운 안에 있어 못 찾았습니다